기계학습개론 Final Project 보고서

IT 공학전공 2216899 정지윤

목차

- I. Network Model (Batch Size, Epoch, Dropout)
- II. Data Processing (Normalization, Augmentation, Initialization)
- III. Optimizer/Scheduler
- IV. Final Code Description

CIFAR10을 학습할 때 팀원들과 함께 정했던 주요 고려사항으로는 크게 네부분이 있는데, Network Model, Data Processing, Epoch, Optimizer/Scheduler 로나눌 수 있다. 매번 나오는 결과에 따라 팀원들끼리 서로 다른 부분을 맡아서 실습했기 때문에 모든 실습이 아래의 순서대로 진행되지는 않았지만, 최종결과가 나오기까지 그동안의 실습 과정을 카테고리 별로 나눠서 설명하는 것이좋을 것 같다고 판단하여 네 부분으로 나눠보았다.

I. Network Model (Batch Size, Epoch, Dropout)

먼저 모델 선정에 관한 부분이다. 팀원들과 함께 테스트해봤던 모델로는 VGG, ResNet, DenseNet 등이 있다. 다른 모델들도 시도해보긴 하였지만 CIFAR10은 깊은 구조를 가진 모델이 적합할 것이라고 판단하여 세 가지로 추려서 탐구해보기로 결정하였다. 또한, 모델에 따라 batch size 와 epoch 을 몇으로 설정해야 GPU 용량이나 시간이 너무 많이 들지 않으면서 동시에 성능이 좋게 나오는지, dropout 을 적용하는 것이 좋을지도 함께 고려해보았다.

① VGG11

```
✓ D # Loss function and optimizer
            loss_fun = nn.CrossEntropyLoss()
            optimizer = torch.optim.Adam(net.parameters(), Ir=0.0001)
            scheduler = torch.optim.lr_scheduler.StepLR(optimizer, step_size=10, gamma=0.1)
Train the network
     Train your own network using the above loss function and optimizer.
✓ [13] # Train the model
            epochs = 20 # number of epochs
            for epoch in range(epochs):
                 loss tmp = 0.0
                 epoch_loss = 0.0
                # Update the learning rate according to the learning rate scheduler
                scheduler.step()
                # Print the enoch loss
                print('[Epoch - %d] Loss: %.3f' %(epoch + 1, epoch_loss / (i+1)))
     [Epoch - 1] Loss: 0.043
           [Epoch - 2] Loss: 0.034
[Epoch - 3] Loss: 0.033
[Epoch - 4] Loss: 0.032
            [Epoch - 5] Loss: 0.032
[Epoch - 6] Loss: 0.029
[Epoch - 7] Loss: 0.028
           [Epoch - 7] Loss: 0.020

[Epoch - 8] Loss: 0.028

[Epoch - 10] Loss: 0.026

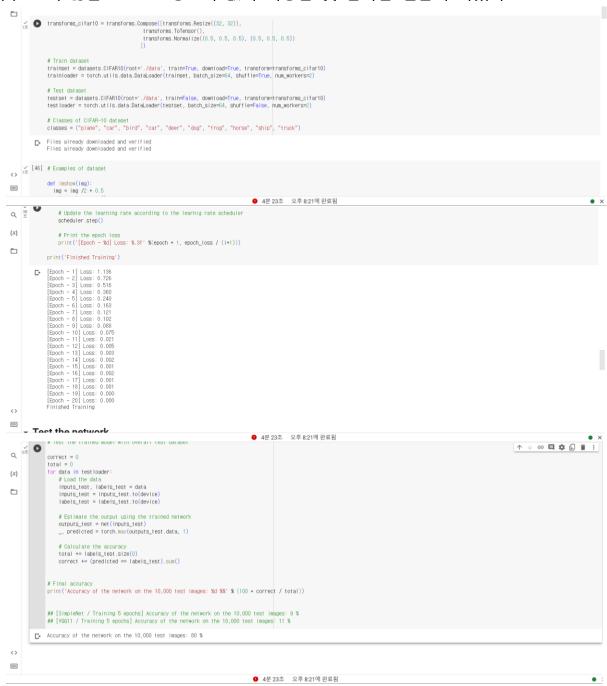
[Epoch - 11] Loss: 0.007

[Epoch - 12] Loss: 0.001
           [Epoch - 13] Loss: 0.001
[Epoch - 13] Loss: 0.001
[Epoch - 14] Loss: 0.001
[Epoch - 15] Loss: 0.000
            [Epoch - 16] Loss: 0.000
# Test the trained model with overall test dataset
     for data in testloader:
         # Load the data
         inputs_test, labels_test = data
inputs_test = inputs_test.to(device)
labels_test = labels_test.to(device)
         # Estimate the output using the trained network
         outputs_test = net(inputs_test)
_, predicted = torch.max(outputs_test.data, 1)
          # Calculate the accuracy
         total += labels_test.size(0)
correct += (predicted == labels_test).sum()
     print('Accuracy of the network on the 10.000 test images: %d %%' % (100 * correct / total))
     ## [SimpleNet / Training 5 epochs] Accuracy of the network on the 10,000 test images: 9 %
     ## [YGG11 / Training 5 epochs] Accuracy of the network on the 10,000 test images: 11 %
```

최초에 학습했던 모델은 VGG11 이었다. 이때는 배치사이즈를 128, 에폭을 20, lr=0.0001 로 수정하였는데 정확도가 79%가 나왔다.

Accuracy of the network on the 10,000 test images: 79 %

그래서 배치를 64로, lr=0.001로 수정해보았더니 80%로 오르는 것을 확인할수 있었다. 여러 번 비교해본 결과 lr은 0.001이 가장 적당하고, 배치사이즈는 너무 크지 않은 64~128정도의 값이 적당한 것 같다는 결론이 나왔다.



② VGG19

VGG19 모델은 처음에 해봤을 때 에폭 20~30, 배치사이즈 64 와 256 이 성능이 80 대로 안정적으로 나왔었다. 그리고 확실히 vgg 는 다른 모델에 비해 시간이 적게 걸린다는 것을 알 수 있었다.

```
↑ ↓ © 目 ‡ 🖟 🖥 🗄
      transforms_cifar10 = transforms.Compose([transforms.Resize((32, 32)), transforms.ToTensor(),
                                                                      transforms.Normalize((0.5, 0.5, 0.5), (0.5, 0.5, 0.5))
                    transform_train = transforms.Compose([
    transforms.RandomCrop(32, padding=4),
    transforms.RandomMorizontalFlip(),
    transforms.Tofensor(),
    transforms.Normalize((0.5, 0.5, 0.5), (0.5, 0.5, 0.5)))]
                    # Train dataset
trainset = datasets.CIFAR10(root='./data', train=True, download=True, transform=transforms_cifar10)
trainloader = torch.utils.data.DataLoader(trainset, batch_slze=64, shuffle=True, num_workers=c)
                     testset = datasets.CIFAR10(root='./data', train=False, download=True, transform=transforms_cifar10) testloader = torch.utils.data.DataLoader(testset, batch_size=64, shuffle=False, num_workers=2)
                    # Classes of CIFAR-10 dataset classes = ("plane", "car", "bird", "cat", "deer", "dog", "frog", "horse", "ship", "truck")
            () [4] # Examples of dataset
                                                                                                                                         ✓ 1초 오후 3:12에 완료됨
       Test the trained model with overall test dataset
                    correct = 0
total = 0
for data in testloader:
  # Load the data
  inputs_test, labels_test = data
  inputs_test = inputs_test.to(device)
  labels_test = labels_test.to(device)
{x}
 # Estimate the output using the trained network
outputs_test = net(inputs_test)
_, predicted = torch.max(outputs_test.data, 1)
                          # Calculate the accuracy
total += labels_test.size(0)
correct += (predicted == labels_test).sum()
                    # Final accuracy
print("Accuracy of the network on the 10,000 test images: %d %%" % (100 - correct / total))
                    ## [SimpleNet / Training 5 epochs] Accuracy of the network on the 10,000 test images: 9 %
## [V8G11 / Training 5 epochs] Accuracy of the network on the 10,000 test images: 11 %
             C→ Accuracy of the network on the 10,000 test images: 85 %
(IIII)
```

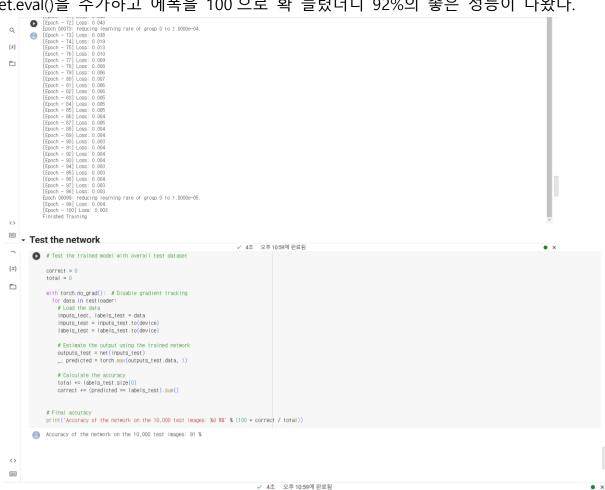
VGG19 배치 64 에폭 20 85%

```
class V0619(nn.Module):
    def __init__(self):
        super(V0619, self).__init__()
        self.features = self.make_layers(cfg['V0619'])
        self.classIfier = nn.Linear(512, 10)
       {x}
       layers += [nn.Conv2d(in_channels, x, kernel_size=3, padding=1),
                                          nn.BatchNorm2d(x),
nn.ReLU()]
in_channels = x
                               return nn.Sequential(*lavers)
                           def forward(self, x):
    out = self.features(x)
    out = out.view(out.size(0), -1)
    out = self.classifier(out)
                     net = VGG19().to(device)
       ===
scheduler = torch.optim.lr_scheduler.StepLR(optimizer, step_size=10, gamma=0.1)
      - Train the network
         Train your own network using the above loss function and optimizer
     y [18] # Train the model
epochs = 30 # number of epochs
            for epoch in range(epochs):
         loss_tmp = 0.0
                                                                                                        ✓ 3초 오후 4:53에 완료됨
       correct = 0
total = 0
for data in testloader:
    #Load the data
    inputs_test, labe!s_test = data
    inputs_test = inputs_test.to(device)
    labe!s_test = labe!s_test.to(device)
       {x}
       # Estimate the output using the trained network outputs_test = net(inputs_test) _, predicted = torch.max(outputs_test.data, 1)
                           # Calculate the accuracy
total += labels_test.size(0)
correct += (predicted == labels_test).sum()
                      print('Accuracy of the network on the 10,000 test images: %d %%' % (100 * correct / total))
                      ## [SimpleNet / Training 5 epochs] Accuracy of the network on the 10,000 test images: 9 %
## [V8G11 / Training 5 epochs] Accuracy of the network on the 10,000 test images: 11 %
       <>
                                                                                                              ✓ 3초 오후 4:53에 완료됨
```

VGG19 배치 256 에폭 30 87%

그리고 초반에 드롭아웃 적용을 했더니 성능이 확 줄었다. 그래서 처음에는 에폭 수가 작아서 드롭아웃을 넣으면 오히려 과적합이 심해져서 정확도가 낮아지는 건가 싶었는데, 마지막에 net.eval()을 적용하지 않아서 그런 것 같다. eval() 함수를 사용하면 모델이 추론 또는 평가를 수행하는 모드로 전환되는데

이는 드롭아웃 또는 배치 정규화 같은 정규화 기법을 평가 모드에 맞게 동작시키는 역할을 한다. 하지만 eval() 함수를 사용하지 않으면 학습 모드로 유지되고 정규화 기법이 다르게 동작할 수 있다고 한다. 따라서 마지막에 net.eval()을 추가하고 에폭을 100으로 확 늘렸더니 92%의 좋은 성능이 나왔다.



net.eval 이 없을 때 91%

net.eval 이 있을 때 92%

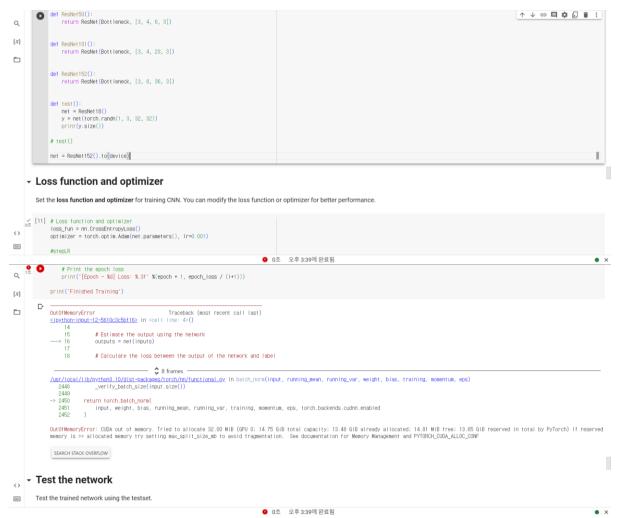
3 ResNet

ResNet18,34는 에폭 30, 배치사이즈 256으로 진행하였는데 전체적으로 성능이좋긴 하지만 80후반에서 더 이상 오르지 않았다. 또한 ResNet 152는 OutOfMemory 오류가 났었다. 아무래도 ResNet은 GPU 용량이 적을 때 사용하기좋은 모델은 아닌 것 같았다.

ResNet18 86%

```
Q ož [37]
                  def ResNet18():
    return ResNet(BasicBlock, [2, 2, 2, 2])
{x}
def ResNet34():
    return ResNet(BasicBlock, [3, 4, 6, 3])
                  def ResNet50():
    return ResNet(Bottleneck, [3, 4, 6, 3])
                  def ResNet101():
    return ResNet(Bottleneck, [3, 4, 23, 3])
                  def ResNet152():
return ResNet(Bottleneck, [3, 8, 36, 3])
def test():
    net = RepNet(18()
    .....v.e net(forch randn(1.3.32.32))
    total = 0
    for data in testloader:
                       # Load the data
{x}
                       inputs_test, labels_test = data
inputs_test = inputs_test.to(device)
                     labels_test = labels_test.to(device)
# Estimate the output using the trained network outputs_test = net(inputs_test)
                      _, predicted = torch.max(outputs_test.data, 1)
                      total += labels_test.size(0)
correct += (predicted == labels_test).sum()
                  print('Accuracy of the network on the 10,000 test images: %d %%' % (100 * correct / total))
                  ## [SimpleNet / Training 5 epochs] Accuracy of the network on the 10,000 test images: 9 % ## [Y6611 / Training 5 epochs] Accuracy of the network on the 10,000 test images: 11 %
            Accuracy of the network on the 10,000 test images: 87 %
```

ResNet34 87%



ResNet152 의 OutOfMemory 에러

(4) DenseNet

DenseNet 이 epoch10 만으로도 87%가 나왔다고 하시는 팀원분의 말을 듣고 마지막으로 DenseNet을 조금 더 다뤄보기로 하였다. 169, 121을 처음에 사용해보았는데 둘 다 OutOfMemory 에러가 나서 121로 캐시 비우는 코드를 추가한후에 에폭 10 또는 15, 배치사이즈를 64로 해보았는데 80후반대의 좋은 성능이나왔다. 하지만 용량의 한계로 에폭을 늘리지 못해서 그런지 80후반에서 더 이상오르지 않았다. 또한 복잡한 레이어 구조를 가지고 있어서 그런지 러닝타임이 1시간 정도로 매우 길었다.

```
Q
                  [] # AS usual, a bit of setup
# If you need other libraries, you should import the libraries.
  {x}
                              import os, sys
import torch
from torch import nn
from torch.nn import functional as F
    import torchvision
import torchvision.transforms as transforms
import torchvision.datasets as datasets
                               import matplotlib.pyplot as plt
import numpy as np
                    # Set the device
device = 'cuda' if torch.cuda.is_available() else 'cpu'
print(device)
                     C→ cuda
                                                                                                                                                                                                               + 코드 — + 텍스트
                  [ ] gc.collect()
torch.cuda.empty_cache()
  ■ - Data Loader
GPU 캐시비우는 코드 추가
   Q
                             class Bottleneck(m,Module):

def __init__(self, in_planes, growth_rate):
    super(Bottleneck, self),__init__():
    self.pni = nn.BatchNorm2d(in_planes)
    self.comvi = nn.Conv2d(in_planes, 4*growth_rate, kernel_size=1, blas=False)
    self.bnz = nn.BatchNorm2d(4*growth_rate)
    self.conv2 = nn.Conv2d(4*growth_rate, growth_rate, kernel_size=3, padding=1, blas=False)
   {x}
    def forward(self, x):
    out = self.conv1(F.relu(self.bn1(x)))
    out = self.conv2(F.relu(self.bn2(out)))
    out = torch.cat([out,x], 1)
    return out
                             class Transition(nn.Module):
    def __init__(self, in_planes, out_planes):
        super(Transition, self)__init__()
        self.bn = nn.Batchform2d(in_planes)
        self.conv = nn.Comv2d(in_planes, out_planes, kernel_size=1, blass=false)
                                       def forward(self, x):
    out = self.comv(F.relu(self.bn(x)))
    out = F.avg_pool2d(out, 2)
    return out
    <>
                             class DenseMet(nn.Module):
    def __init__(self, block, nblocks, growth_rate=12, reduction=0.5, num_classes=10):
        super(DenseMet, self),__init__()
    class Uensevet(nn.Module):
    def __init__(self, block, nblocks, growth_rate=12, reduction=0.5, num_classes=10):
    super(DenseNet, self).__init__()
    self.growth_rate = growth_rate
    Q
    {x}
                                               num_planes = 2*growth_rate
self.convl = nn.Conv2d(3, num_planes, kernel_size=3, padding=1, blas=False)
    self.densel = self._make_dense_layers(block, num_planes, nblocks[0])
num_planes += nblocks[0]*prowth_rate
out_planes = inf(math.floor(num_planes*reduction))
self.transl = Transltion(num_planes, out_planes)
num_planes = out_planes
                                               self.dense2 = self._make_dense_layers(block, num_planes, nblocks[1])
num_planes += nblocks[1]=growth_rate
out_planes = inf(math.floor(num_planes+reduction))
self.trans2 = Transition(num_planes, out_planes)
num_planes = out_planes
                                               self.dense3 = self._make_dense_layers(block, num_planes, nblocks[2])
num_planes += nblocks[2]+growth_rate
out_planes = inf(math.floor(num_planes+reduction))
self.trans3 = Transition(num_planes, out_planes)
num_planes = out_planes
                                               self.dense4 = self._make_dense_layers(block, num_planes, nblocks[3]) num_planes += nblocks[3]*growth_rate
```

self.bn = nn.BatchNorm2d(num_planes)
self.linear = nn.Linear(num_planes, num_classes)

<> ===



DenseNet121 88%

아무래도 ResNet 과 DenseNet 은 GPU의 한계와 시간이 너무 많이 걸리는 관계로 에폭 사이즈를 많이 늘리지 못해서 작은 에폭으로도 80 후반의 성능이 나오긴 하지만 그 이상의 성과를 기대하기는 어려웠다. 이런 면에서 vgg 가 가장 적합했던 것 같다. 시간도 적게 걸리고 에폭을 늘려도 gpu 소모가 크지 않고 다양한 조합을 시도해 볼 수 있기 때문이다.

- II. Data Processing (Normalization, Augmentation, Initialization)
 - (1) Normalization

초반에 VGG 모델에서 normalize(0.4914, 0.4822, 0.4465), (0.247, 0.243, 0.261)로 바꾸어 봤는데 성능이 떨어지거나 별 차이가 없었다.

그래서 인터넷과 ChatGPT를 통해 검색해본 결과 CIFAR-10 데이터셋에 가장적합한 정규화(normalization) 값은 일반적으로 평균(mean)을 0으로, 표준 편차(standard deviation)를 1로 조정하는 것이며 CIFAR-10은 픽셀의 값이 0부터 255까지의 범위를 가지는 RGB 이미지로 구성되어 있기 때문에 평균을 0으로 조정하기 위해서 255로 나누고, 표준 편차를 1로 조정하기 위해서 255로 나눈 값을 사용하는 것이 좋다고 한다. 따라서 CIFAR-10 데이터셋을 정규화 할 때는 평균(Mean): [0.5, 0.5, 0.5], 표준 편차(Standard Deviation): [0.5, 0.5, 0.5]로 설정하면 RGB의 평균이 0.5로, 표준 편차가 0.5로 조정되어 더욱 좋은 결과가나올 수 있다고 한다. 그래서 Normalization 값은 바꾸지 않고 다시 0.5로 설정하여 진행하였다.

② Augmentation

Augmentation 을 초기에 아래 사진과 같이 추가했는데, Augmentation 적용이 안되고 있었다. transforms_cifar10 부분을 transform_train 으로 바꾸어야 적용이 된다는 것을 나중에 발견하였다. 따라서 DenseNet 을 실습하면서 해당 부분을 수정하였는데 성능이 오히려 떨어졌었다.

```
Transforms. Normal 12et (0.5, 0.5, 0.5), (0.5, 0.5, 0.5))

Itransforms. Transforms. Remains 12et (0.5, 0.5, 0.5), (0.5, 0.5, 0.5))

Itransforms. Remains 12et (0.5, 0.5, 0.5), (0.5, 0.5, 0.5))

Itransforms. Remains 12et (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1.6) (1
```

Augmentation 초기 적용 모습

✓ 19초 오후 5:37에 완료됨

Augmentation 적용을 다시 수정한 모습

```
self.bn = nn.BatchNorm2d(in_planes)
self.conv = nn.Conv2d(in_planes, out_planes, kernel_size=1, bias=False)
                                                                                                                                                                                                 ↑ ↓ © □ ‡ [ i i
 Q
                   def forward(self, x):
    out = self.conv(F.relu(self.bn(x)))
    out = F.avg_pool2d(out, 2)
    return out
 \{x\}
 def initialize_weights(g):

if isinstance(g, mn.com/dd):
    mn.init.kalaing_uniform_(m.weight.data,nonlinearity='relu')
    if m.bias is not Norie:
    nn.init.constant_(m.bias.data, 0)
elif isinstance(g, mn.BatchNorm2d):
    nn.init.constant_(m.weight.data, 1)
    nn.init.constant_(m.weight.data, 0)
elif isinstance(g, mn.Linear):
    nn.init.constant_(m.bias.data, 0)
nn.init.constant_(m.bias.data, 0)
              class DenseMet(nn.Module):
    def __init__(self, block, nblocks, growth_rate=12, reduction=0.5, num_classes=10):
    supr(DenseMet, self).__init__()
    self.growth_rate = growth_rate
                       num_planes = 2*growth_rate self.conv1 = nn.Conv2d(3, num_planes, kernel_slze=3, padding=1, blas=False)
 ()
                        self.densel = self._make_dense_layers(block, num_planes, nblocks[0])
num_planes += nblocks[0]*growth_rate
out_planes = int(math.floor(num_planes*reduction))

    Loss function and optimizer

 Q
          Set the loss function and optimizer for training CNN. You can modify the loss function or optimizer for better performance.
 {x}
         [] # Loss function and optimizer
loss_fun = nn.CrossEntropyLoss()
optimizer = torch.optim.Adam(net.parameters(), Ir=0.001)
 scheduler = torch.optim.lr_scheduler.StepLR(optimizer, step_size=5, gamma=0.1)

    Train the network

          Train your own network using the above loss function and optimizer.
         [ ] # Train the model
epochs = 15 # number of epochs
               for epoch in range(epochs):
                   for i, data in enumerate(trainloader, start=0):
# Load the data
inputs, labels = data
inputs = inputs. to(device)
labels = labels.to(device)
 <>
 # Test the trained model with overall test dataset
        correct = 0
         total = 0
         for data in testloader:
                # Load the data
                inputs_test, labels_test = data
                inputs_test = inputs_test.to(device)
                labels_test = labels_test.to(device)
                # Estimate the output using the trained network
                outputs_test = net(inputs_test)
                _, predicted = torch.max(outputs_test.data, 1)
                # Calculate the accuracy
                total += labels_test.size(0)
                correct += (predicted == labels_test).sum()
         # Final accuracy
        print('Accuracy of the network on the 10,000 test images: %d %%' % (100 * correct / total))
         ## [SimpleNet / Training 5 epochs] Accuracy of the network on the 10,000 test images: 9 %
         ## [YGG11 / Training 5 epochs] Accuracy of the network on the 10,000 test images: 11 %
```

DenseNet121 에서 Augmentation 과 Initialization 을 넣었을 때 정확도가 76%로 감소한 모습

아마도 DenseNet 에서는 에폭 수가 작아서 Augmentation을 넣으면 과적합(Overfitting)과 원본 데이터 왜곡이 더 도드라지게 일어나서 성능이 떨어지는 것 같다.

그래서 마지막에 VGG19 모델 에폭 100으로 vertical flip 부분을 지우고 brightness, contrast, saturation, hue 값을 0.1로 줄여서 적용했더니 아래 사진과 같이 성능이 92%로 오르는 것을 확인할 수 있었다.

```
▶ transforms_cifar10 = transforms.Compose([transforms.Resize((32, 32)),
                                                                                                   transforms.ToTensor()
                                                                                                   transforms.Normalize((0.5, 0.5, 0.5), (0.5, 0.5, 0.5))
            # Data augmentation
            transform train = transforms.Compose([
                      transforms.RandomCrop(32, padding=4),
                      transforms.RandomHorizontalFlip(),
                      transforms.ColorJitter(brightness=0.1, contrast=0.1, saturation=0.1, hue=0.1),
                      transforms.ToTensor()
                     transforms.Normalize((0.5, 0.5, 0.5), (0.5, 0.5, 0.5))
            # Train dataset (with data augmentation)
            trainset = datasets.CIFAR10(root='./data', train=True, download=True, transform=transform_train)
           trainloader = torch.utils.data.DataLoader(trainset, batch_size=256, shuffle=True, num_workers=2)
            # Test dataset (without data augmentation)
           testset = datasets.CIFAR10(root='./data', train=False, download=True, transform=transforms_cifar10)
           testloader = torch.utils.data.DataLoader(testset, batch_size=256, shuffle=False, num_workers=2)
           classes = ("plane", "car", "bird", "cat", "deer", "dog", "frog", "horse", "ship", "truck")
Downloading <a href="https://www.cs.toronto.edu/~kriz/cifar-10-python.tar.gz">https://www.cs.toronto.edu/~kriz/cifar-10-python.tar.gz</a> to ./data/cifar-10-python.tar.gz to ./data/cifar-10-python.t
           Files already downloaded and verified
         _{3 \pm} [9] # Test the trained model with overall test dataset
{x}
 with torch.no_grad(): # Disable gradient tracking
                            met.eval()
for data in testloader:
# Load the data
inputs_test, labels_test = data
inputs_test = inputs_test.to(device)
labels_test = labels_test.to(device)
                        #Final accuracy
print('Accuracy of the network on the 10,000 test images: %d %%' % (100 * correct / total))
                         Accuracy of the network on the 10,000 test images: 92 %
```

(3) Initialization

"He 초기화 (He Initialization): He 초기화는 ReLU(렐루)와 같은 활성화 함수를 사용하는 신경망에 적합한 초기화 방법입니다. He 초기화는 가중치를 랜덤하게 초기화할 때, 표준 편차를 sqrt(2/n)으로 설정하여 초기화합니다."

chatGPT 에서 다음과 같은 내용을 찾아보고 우리는 ReLU를 사용하기 때문에 He Initialization을 추가하기로 하였다. 하지만 처음에는 적용이 잘 안되었는지 효과가 좋지 않았다. 특히 DenseNet 에서는 에폭 수가 적어서 그런지 성능이 확떨어졌다.

```
self.bn = nn.BatchNorm2d(in_planes)
                                                                                                                                                                        ↑ ↓ © □ ‡ [ i :
                    self.conv = nn.Conv2d(in_planes, out_planes, kernel_size=1, blas=False)
Q
                def forward(self, x):
    out = self.conv(F.relu(self.bn(x)))
{x}
                    out = F.avg_pool2d(out, 2)
def initialize_weights(m):
   if isinstance(m, nn.Conv2
              If isinstance(w, nn.conv20):

nn.init.kaining_uniforw_(m.weight.data,nonlinearity='relu')

if m.blas is not None:
nn.init.constant_(m.blas.data, 0)

elif isinstance(m, nn.BatchNonn20):
nn.init.constant_(m.blas.data, 1)
nn.init.constant_(m.blas.data, 0)

elif isinstance(m, nn.Linear):
                 nn.init.kaiming_uniform_(m.weight.data)
                nn.init.constant_(m.bias.data, 0)
             class DenseMet(nn.Module):
    def __init_(self, block, nblocks, growth_rate=12, reduction=0.5, num_classes=10):
    super(DenseMet, self).__init__()
    self.growth_rate = growth_rate
                    num_planes = 2*growth_rate
self.conv1 = nn.Conv2d(3, num_planes, kernel_size=3, padding=1, bias=False)
                    self.dense1 = self._make_dense_layers(block, num_planes, nblocks[0])
===
                    num_planes += nblocks[0]*growth_rate
out planes = int(math.floor(num planes*reduction))
 # Test the trained model with overall test dataset
         correct = 0
         total = 0
         for data in testloader:
               # Load the data
               inputs_test, labels_test = data
               inputs_test = inputs_test.to(device)
               labels_test = labels_test.to(device)
               # Estimate the output using the trained network
               outputs_test = net(inputs_test)
               _, predicted = torch.max(outputs_test.data, 1)
               # Calculate the accuracy
               total += labels_test.size(0)
               correct += (predicted == labels_test).sum()
         # Final accuracy
        print('Accuracy of the network on the 10,000 test images: %d %%' % (100 * correct / total))
         ## [SimpleNet / Training 5 epochs] Accuracy of the network on the 10,000 test images: 9 %
         ## [YGG11 / Training 5 epochs] Accuracy of the network on the 10,000 test images: 11 %
```

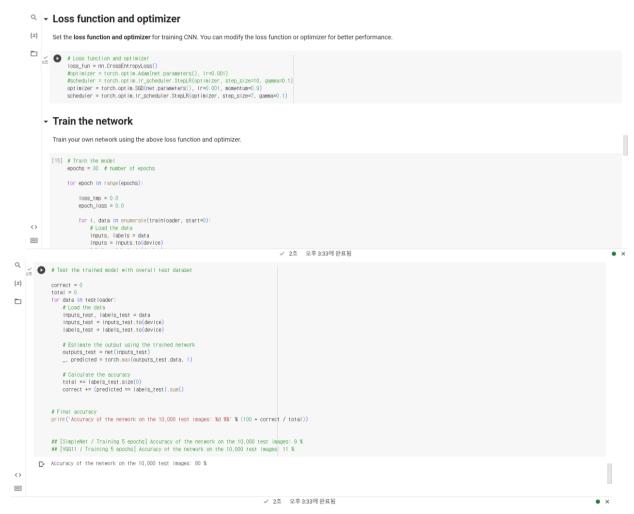
Accuracy of the network on the 10,000 test images: 76 %

DenseNet 에서 처음 He Initialization 을 추가하였더니 정확도가 줄어든 모습

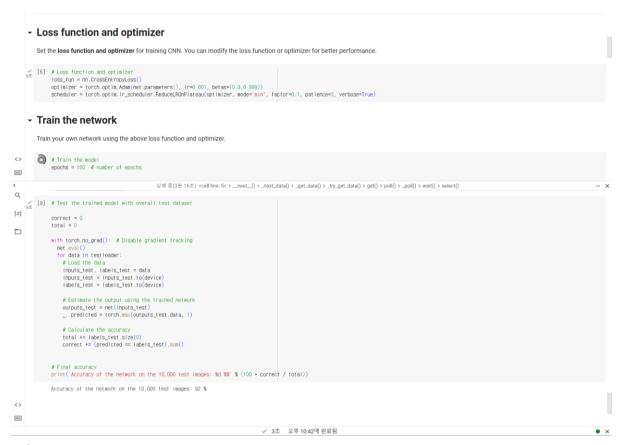
이후에 이 부분도 Augmentation 과 마찬가지로 net.eval()함수를 적용하였더니해결되었다. 확실히 Augmentation 과 Initialization은 넣는 것이 정확도 향상에 도움이 되며 eval 함수를 사용하여 평가모드로 진행하는 것이 효과가 좋은 것같다.

III. Optimizer/Scheduler

옵티마이저는 SGD와 비교해본 결과 Adam 이 더 좋았던 것 같다. Adam 은 momentum 이 없어서 betas 나 weight decay 를 사용하며, Adam 옵티마이저에 적절한 betas 값은 일반적으로 기본값인 0.9 와 0.999 를 사용하는 것이 좋다고한다.



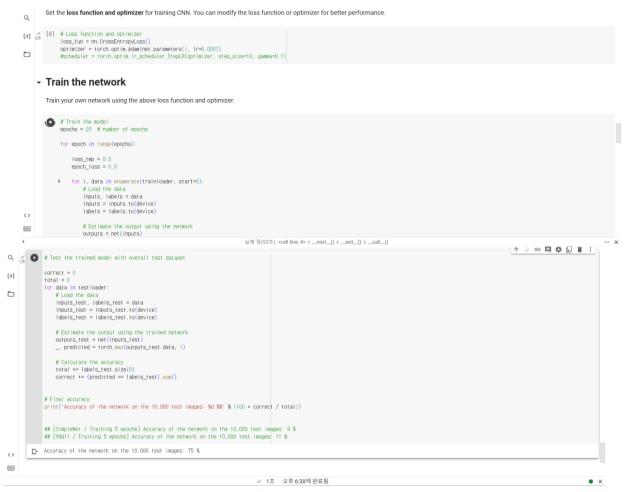
SGD 80%



Adam 92%

스케줄러는 팀원들끼리 10 개의 스케줄러를 검색하여 이를 나눠서 사용해보았는데 스케줄러의 차이만 확인하기 위해 모델은 vgg19, 에폭 30 과 배치사이즈 256 으로 고정해서 진행하였다. 나는 그중에서 LambdaLR, MultiplicativeLR, StepLR, MultiStepLR 4 개를 맡았다. 그랬더니 결과가 다음과 같았다.

LambdaLR 82%
MultiplicativeLR 85%
StepLR 87%
MultiStepLR 86%



스케줄러 없는 경우 75%

다른 팀원의 결과는 다음과 같았다.

ExponentialLR 70%

CosineAnnealingLR 78%

ReduceLROnPlateau 76%

또 다른 팀원분은 CyclicLR, CyclicLR, CosineAnnealingWarmRestarts 3 개를 해봤는데 눈에 띄는 결과가 없어서 그냥 무시하기로 하였다. 그리고 다양한 자료들을 찾아본 결과 CIFAR10 에는 StepLR, LambdaLR, ReduceLROnPlateau 가자주 사용되어서 스케줄러는 세 가지 정도로 추리기로 하였다.

stepLR 은 아래 사진과 같이 평균적으로 좋은 성능을 내긴 하지만 80 후반에서 더 이상 오르지 않았다.

```
class VGG19(nn.Module)
       \{x\}
                                __init__(self):
super(v6619, self).__init__()
self.features = self.make_layers(cfg['V6619'])
self.classifier = nn.Linear(512, 10)
        def make_layers(self, cfg):
    layers = []
                                 in_channels = 3
for x in cfg:
    if x == 'M':
                                          layers += [nn.MaxPool2d(kernel_size=2, stride=2)]
                                          layers += [nn.Conv2d(in_channels, x, kernel_size=3, padding=1),
                                          nn.BatchNorm2d(x),
nn.ReLU()]
in_channels = x
                                return nn.Sequential(*layers)
                           def forward(self, x):
    out = self.features(x)
    out = out.view(out.size(0), -1)
    out = self.classifier(out)
                    net = VGG19().to(device)
                                                                                                                   ✓ 3초 오후 4:53에 완료됨
scheduler = torch.optim.lr_scheduler.StepLR(optimizer, step_size=10, gamma=0.1)
                 #scheduler = torch.optim.ir_scheduler.LambdaLR(optimizer=optimizer, ir_lambda=lambda epoch: 0.95 ** epoch)
                 #MultiplicativeLR
#scheduler = torch.optim.lr_scheduler.MultiplicativeLR(optimizer=optimizer,lr_lambda=lambda epoch: 0.95 ** epoch)
                #MultiStepLR #scheduler = torch.optim.lr_scheduler.MultiStepLR(optimizer, milestones=[30,80], gamma=0.5)
      - Train the network
          Train your own network using the above loss function and optimizer.
            for epoch in range(epochs):
correct = 0
total = 0
for data in testloader:
    # Load the data
    inputs_test, labe!s_test = data
    inputs_test = inputs_test.to(device)
    labe!s_test = labe!s_test.to(device)
                    # Estimate the output using the trained network
outputs_test = net(inputs_test)
_, predicted = torch.max(outputs_test.data, 1)
                     # Calculate the accuracy
total += labels_test.size(0)
correct += (predicted == labels_test).sum()
                # Final accuracy
print('Accuracy of the network on the 10,000 test images: %d %%' % (100 * correct / total))
                ## [SimpleNet / Training 5 epochs] Accuracy of the network on the 10,000 test images: 9 %
## [VGG11 / Training 5 epochs] Accuracy of the network on the 10,000 test images: 11 %
           Accuracy of the network on the 10,000 test images: 87 %
==
                                                                                                          ✓ 3초 오후 4:53에 완료됨
```

그래서 아래 사진과 같이 ReduceLROnPlateau 에서 인자를 몇 개 줄이고 적용해보았더니 에폭이 100으로 커져서 그런지 효과가 좋았던 것 같다. ReduceLROnPlateau 는 주어진 횟수의 epoch 동안 loss function 이 개선되지 않을 때 학습률을 조절해준다. 에폭이 클수록 loss 가 줄지 않고 정체되는 경우가 많은 것 같아서 이때 이 스케줄러가 큰 역할을 하는 것 같았다.

```
Q
                  [] # Loss function and optimizer
ioss_fun = nn.crossEntropyLoss()
optimizer = torch.optim.Adm(net.parameters(), Ir=0.001, betas=(0.9,0.999))
scheduler = torch.optim.ir_scheduler.ReduceLROnPlateau(optimizer, mode='min', factor=0.1, patience=3, verbose=True)
        \{x\}

    Train the network

                   Train your own network using the above loss function and optimizer.
                               for i, data in enumerate(trainloader, start=0):
    # Load the data
    inputs, labels = data
    inputs = inputs. to(device)
    labels = labels.to(device)
        <>
       # Calculate the loss between the output of the network and label
                  Q
{x}

    Test the network

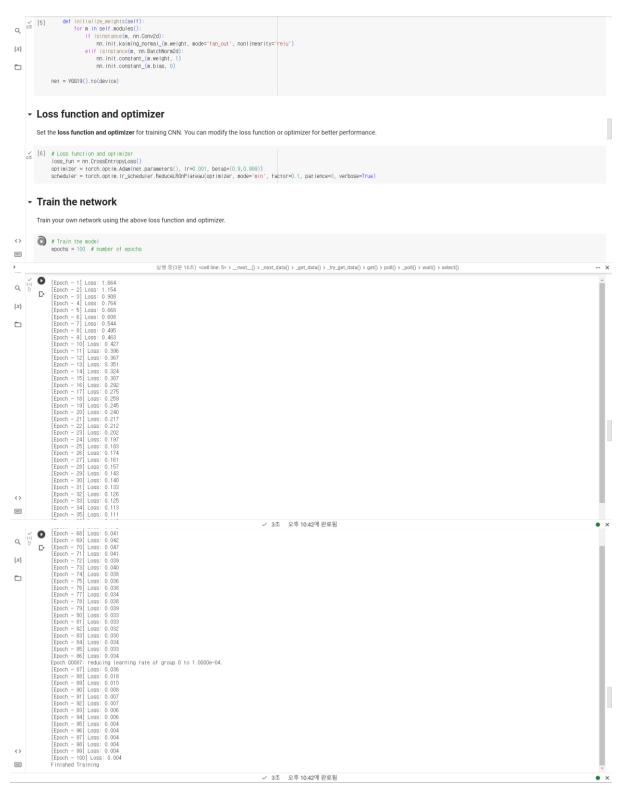
           Test the trained network using the testset.
           Accuracy of the network on the 10,000 test images is the final accuracy of your network.
           The closer the accuray is to 100%, the better the network classifies the input image
          [ ] # Test the trained model with sample
                  dataiter_test = iter(testloader)
img_test, labels_test = next(dataiter_test)
<>
imshow(torchvision.utils.make_grid(img_test))
Q
                  with torch.no_grad(): # Disable gradient tracking
for data in testloader:
# Load the data
inputs_test, labels_test = data
inputs_test = inputs_test to(device)
labels_test = labels_test.to(device)
\{x\}
# Estimate the output using the trained network outputs_test = net(inputs_test)
_, predicted = torch.max(outputs_test.data, 1)
                        # Calculate the accuracy
total += labels_test.size(0)
correct += (predicted == labels_test).sum()
                  # Final accuracy
print('Accuracy of the network on the 10,000 test images: %d %%' % (100 * correct / total))
           Accuracy of the network on the 10,000 test images: 91 %
<>
```

IV. Final Code Description

최종 제출 코드를 간단히 설명해보았다.

Augmentation 적용 시 ColerJitter 값 0.1 로 적용하여 과적합이 일어나지 않도록 적당한 값으로 줄여주었다.

VGG19 가 적은 GPU 로도 잘 돌아가고 에폭을 늘려도 시간이 오래 걸리지 않고다양한 조합의 차이를 확인할 수 있어서 효율적이기 때문에 이 모델로선정하였다.



Initialization 은 ReLU 와 잘 맞는 He Initialization 을 적용하여 정확도를 높였다. 또한 optimizer는 가장 효과가 좋았던 Adam 으로, scheduler는 loss function 이 개선되지 않을 때 학습률을 조절해주는 ReduceLROnPlateau를 사용하였다. 에폭은 100 으로 해서 loss를 많이 줄일 수 있도록 하였다.

```
| Section | Sect
```

최종 결과로 정확도가 92%가 나왔다.

참고문헌: chatGPT, [PyTorch] Weight Initialization (기울기 초기화) (tistory.com), [PyTorch] PyTorch 가 제공하는 Learning rate scheduler 정리 (tistory.com), GitHub 모델 별 코드 정리 https://github.com/kuangliu/pytorch-cifar/tree/master/models, Weights & Biases (wandb.ai),